

# 大專生研究計畫及目前研究成果

## 建立顏色特徵為基礎之機器學習分類器——以辨識蘭花品種為例

### (一)摘要

蘭花是台灣重要花卉外銷作物之一，由於其品種開發多樣性高，若僅以肉眼辨識，將花費大量時間及人力成本，降低蘭花的經濟價值。因此，我希望能建立一個蘭花顏色辨識系統，幫助蘭花育種者在蘭花分析上能更快速、精確，幫助他們研發蘭花品種，增加台灣蘭花的經濟價值。

目前已經有相關的研究提出關於植物的辨識系統，使用的方法皆不盡相同，本研究考慮蘭花花朵影像不同顏色空間，其中包括 RGB 空間(RGB space)、HSV 空間(HSV space)、CIE Lab 空間(CIE Lab space)、YCbCr 空間(YCbCr space)，也使用每像素只考慮深淺的灰階(Gray scale)，並結合以卷積神經網路 (Convolutional Neural Network, CNN)為基礎的 AlexNet、VGG16(Visual Geometry Group 16)、ResNet(Residual Neural Network)、DenseNet 機器學習模型對蘭花影像提取顏色特徵後，再對蘭花品種進行花被片、斑點顏色分類。

### (二)研究動機與研究問題

身為蘭花產業強國的台灣蝴蝶蘭年產量約有 1 億 3294 萬株，2008 年出口總值更是達到 5200 萬美元 (楊玉婷，2010 年，頁 37)，發展品種優良的蘭花是目前的趨勢，為培育出經濟價值蘭花，蘭花的育種技術不斷精進。但現今育種者多以人工方式辨識蘭花品種，而蘭花的種類多元多變，造成育種者在蘭花辨識工作量增加，甚至遇上難以用肉眼辨別的相近蘭花品種，這些問題都讓台灣蘭花產業陷入瓶頸。若是能有效率、有系統地整理蘭花的品種，讓育種者能明瞭的識別蘭花品種，減輕他們繁瑣的工作內容，讓他們未來只需花費短短幾分鐘的時間即可初步判斷蘭花花朵的各項特點，節省辨識蘭花的時間，即可提升台灣蘭花產業的競爭力。

顏色是蘭花的重要特徵，因此本研究希望能藉由機器學習的技術對蘭花的影像資料進行顏色的定量分析，並利用此顏色特徵來建議建立蘭花品種分類器。未來育種者只需透過蘭花的影像，即可判斷蘭花種類，相信該研究成果可以節省育種者在辨識蘭花品種上的時間。茲將本研究的架構說明如圖 1 所示：




圖 1 研究流程圖

### (三)文獻回顧與探討

茲將文獻分成前處理、以顏色為基礎的分類方法兩個部分進行回顧。

#### 1. 前處理—顏色辨識

RGB 顏色空間(RGB color space)是最常使用的顏色表示方法，但 Sağ and Çunkaş (2015) 指出原色 (Primary) 還有包含亮度 (Luminance—chrominance)、感知色空間 (Perceptual color spaces)，為了能分辨影像的顏色與亮度 Sağ and Çunkaş (2015)建議使用 HSV 空間(hue, saturation and value space)提取顏色特徵，Garcia-Lamont et al. (2018) 為了評估分割影像顏色方法的表現，彼等針對常見的顏色空間，其分別有 RGB 空間、HSV 空間、HSI 空間、CIE XYZ 空間、CIE Lab 空間、YUV 空間、YCbCr 空間進行研究，最後 Garcia-Lamont et al. (2018)指出各方法都有優缺點，沒有一個最好的方法分割影像顏色區塊，將每種方法使用於適當時機，才能達到最好的分割影像顏色。Sağ and Çunkaş (2015)和 Garcia-Lamont et al. (2018) 皆提出彩色影像的顏色分割方法，都不是針對某特定的物體影像，針對不同影像所運用到的最佳顏色辨識方法不盡相同。

Kendal et al. (2013)提及了使用 RGB 空間提取顏色時，可能會發生色彩剪切(colour clipping)，而導致顏色資訊遺失，當影像為 JPEG 檔時，可能由於影像在相機處理和壓縮，而顏色資訊遺失；但當影像為 RAW 圖檔（未經處理的圖檔）時，由於在相機中的處理較少，相較之下不會遺失顏色資訊。

由於 RGB 空間與主要照明條件（亮度和顏色）及記錄圖像傳感器(the recording image sensor)的靈敏度相關，Kendal et al. (2013)提出需將影像標準化，他們調整四個影像參數來達到標準化，分別調整藍色到黃色顏色軸上的靈敏度、紅色到綠色的顏色的靈敏度、調整曝光度以調節整體亮度、調整黑點(black point)以減少絕對最低亮度，結果發現，雖然經過標準化程序，但 5 種相機的得到的 CIE Lab 空間也不一定相同。

#### 2. 花朵顏色分類

Kim and Yu (2017)建立了一個可以在 Android 平台上使用 OpenCV 的花朵識別系統，他們使用 K-means 方法將 12 種花朵分成 4 種顏色分類。首先，將顏色分成三個數值分別對應到紅、綠、藍，數值介於 0-255 間，再指定 4 個中心點，分別對應到白色、黃色、紅色、粉色，並用歐式距離算出每一個顏色離中心點的距離。結果發現，黃色和紅色沒有分類上錯誤的問題，而白色和粉色則有少數分類上的錯誤。

Guru, Sharath, and Manjunath (2010)對於花朵紋理特徵採取灰階共生矩陣(Gray level co-occurrence matrix)和 Gabor responses，再使用 threshold based method 分割花朵影像，將影像轉成 HSV 和色彩直方圖(Color Histograms)，色彩直方圖指出影像屬於背景和花朵的相對應直方圖強度值。再使用 KNN(K-nearest neighbor)分類器分類不同種類的花朵。當分成 10 群時，有最好的分類結果，精確度有高達 98.88%。

Toğaçar et al. (2020)製作了一個花朵分類系統，他們使用的特徵來自於 RGB 空間數值，並使用以 CNN 為基礎的模型分別為 AlexNet、GoogLeNet、ResNet50、VGG16 用於提取特徵，共獲得 4000 個深層特徵，再使用 f 回歸和 MIC 方法將特徵由好到壞排列，最後再使用 SVM 模型將花朵分為雛菊、蒲公英、玫瑰、向日葵、鬱金香，影像皆為 JPG 格式，結果發現，使用 ResNet-50 模型、AlexNet 模型、使用 GoogLeNet 模型、VGG-16 模型時，分類準確度分別為 89.51%、87.06%、88.56%、86.51%。

Liu et al. (2019)提出辨識菊花品種的系統，他們將資料分成兩類，第一個是收集同一視角拍攝的菊花，他們在每一個像色的 RGB 空間值中訓練 DCNN(Deep convolutional neural network)，包含特徵提取器及分類器組成的工具，可用於識別菊花品種，由於拍攝花朵的視角會影響識別結果，因此有了第二種資料，是從各種角度拍攝的菊花，藉由 T-SNE(T-Distributed stochastic embedding)觀察品種分布，再使用 Grad-CAM(Gradient-weighted Class Activation Mapping)方法從人類的角度解釋深度學習的決策過程，並使用 ResNet50 和 VGG16 進行特徵提取，最後再使用 DCNN 識別菊花品種，結果發現使用 ResNet50 模型、VGG16 模型的準確度分別為 69.86%、51.93%，準確度不是很高，但每張圖像分析的時間只需要 10-15 毫秒。

陳偉文 et al. (2020)提出火龍果與荔枝的影像辨識及分類技術，首先提取農作物特徵，包含 11 項植物植被指數、色彩分布、紋理、形狀大小。對於色彩特徵是採用色彩直方圖，任意顏色空間皆可使用此方法，而在此研究中使用表 RGB 顏色的強弱分布情形的表現結果較佳。最後再利用上述特徵和其特徵組合分別使用 2D-CNN、AlexNet、VGG16、ResNet50、Inception-v1、Inception-v3、InceptionResNet-v2 模型提取特徵，再使用隨機森林分類器分類火龍果與荔枝，最後準確率達到 91.35%。

#### (四)研究方法及步驟

本研究方法分成兩個部分，第一個部分為影像資料的前處理，第二部分為以 CNN 為基礎的模型提取顏色特徵，並以顏色分類蘭花影像，茲將研究方法說明如下：

##### 1. 影像資料前處理

由於每種顏色空間使用於不同影像中都各有優缺點，因此影像提取 RGB 空間後，便分別轉換成灰階值、HSV 空間、CIE Lab 空間、YCbCr 空間，再透過各個顏色空間比較好壞得到何種顏色空間較適用於蘭花影像。茲將各顏色空間的轉換方式說明如下，RGB 空間的三個值是(r,g,b)其分別為紅、綠、藍的座標，則由 RGB 空間轉換成灰階值、其他顏色空間的方法為：

##### (1) 灰階：

$$Gray = r \times 0.299 + g \times 0.587 + b \times 0.114$$

灰階是每像素只有一個採樣顏色的方法，依照顏色的深淺及影像亮度不同，除了可顯示全黑或全白兩種顏色，還可以顯示不同程度的灰色，數值介於 0 到 255 之間，共 256 種色階。

(2) HSV 空間：

$$h = \begin{cases} 0^\circ, & \text{if } \max = \min \\ 60^\circ \times \frac{g - b}{\max - \min} + 0^\circ, & \text{if } \max = r \text{ and } g \geq b \\ 60^\circ \times \frac{g - b}{\max - \min} + 360^\circ, & \text{if } \max = r \text{ and } g < b \\ 60^\circ \times \frac{b - r}{\max - \min} + 120^\circ, & \text{if } \max = g \\ 60^\circ \times \frac{r - g}{\max - \min} + 240^\circ, & \text{if } \max = b \end{cases}$$

$$l = 0.5(\max + \min), \quad s = \begin{cases} 0, & \text{if } l = 0 \text{ or } \max = \min \\ \frac{\max - \min}{2l}, & \text{if } 0 < l \leq 0.5 \\ \frac{\max - \min}{2 - 2l}, & \text{if } l > 0.5 \end{cases}$$

$$s = \begin{cases} 0, & \text{if } l = 0 \text{ or } \max = \min \\ \frac{\max - \min}{2l}, & \text{if } 0 < l \leq 0.5 \\ \frac{\max - \min}{2 - 2l}, & \text{if } l > 0.5 \end{cases}$$

(3) YCbCr 空間：

$$\begin{aligned} Y &= 0.257r + 0.564g + 0.098b + 16 \\ Cb &= -0.148r - 0.291g + 0.439b + 128 \\ Cr &= 0.439r - 0.368g - 0.071b + 128 \end{aligned}$$

Y、Cb、Cr 範圍在 0 到 255 之間，Y 表示明亮度、Cb 是藍色與 RGB 亮度值之間差異、Cr 是紅色與 RGB 亮度值之間差異，具有將色度與亮度分離的特性。

(4) CIE Lab 空間：

$$L = \begin{cases} 116 \times \left(\frac{Y}{Y_n}\right)^{1/3} - 16, & \frac{Y}{Y_n} > 0.008856 \\ 903.3 \times \frac{Y}{Y_n}, & \text{otherwise} \end{cases}$$

$$a = 500 \times \left(f\left(\frac{X}{X_n}\right) - f\left(\frac{Y}{Y_n}\right)\right), \quad b = 200 \times \left(f\left(\frac{X}{X_n}\right) - f\left(\frac{Z}{Z_n}\right)\right)$$

$$f(t) = \begin{cases} t^{1/3}, & t > \left(\frac{6}{29}\right)^3 \\ \frac{1}{3}\left(\frac{29}{6}\right)^2 t + \frac{16}{116}, & \text{otherwise} \end{cases}$$

其中 L 為亮度值，範圍介於 0 到 100 之間；a 描述綠色到紫紅色，範圍介於 -500 到 500 之間；b 描述藍到黃色，範圍介於 -200 到 200 之間。自然界中任何顏色都可以使用 CIE Lab 空間表現，且 CIE Lab 空間也比 RGB 空間大，因此 RGB 所能描述的顏色都能在 CIE Lab 空間中反映。

## 2. 使用 CNN 模型提取顏色特徵

得到比較適合蘭花影像的顏色空間特徵後，再使用以 CNN 為基礎的各方法提取顏色特徵並分類蘭花影像。CNN 的基本結構如下圖 2 所示，詳細說明如下方敘述：(以輸入 RGB 空間為例)




圖 2 CNN 流程圖

### (1) 輸入影像轉為數據

由於蘭花影像 RGB 影像，CNN 的輸入為 3 維，包含了影像的長度、寬度、深度，深度即為紅綠藍三個通道所形成的，本研究分別輸入灰階值、RGB 空間、HSV 空間、CIE Lab 空間、YCbCr 空間。

### (2) 卷積運算(Convolution operation)

首先建立維度為  $3 \times 3 \times 3$  的過濾器(filter)，分別對應紅綠藍三個通道，過濾器從圖片左往右、由上往下移動做矩陣運算，每次移動的步長皆相同（如下圖 3(a)），當過濾器將整張影像掃描後，再將三個通道相加，形成一通道，即可將三通道的影像形成一個特徵圖像(feature map)，每一個過濾相當於提取一個特徵圖像，且每一層卷積層會輸出一張特徵圖像（如下圖 3(b)）。




圖 3 (a) 過濾器在影像中掃描方式 (b) 特徵圖像輸出方式

### (3) 最大池化層(Max pooling)、平均池化層(Average pooling)

即是將卷積層的資訊壓縮，例如下圖是使用  $2 \times 2$  核(kernel)，使用取最大值方法計算，即為最大池化層；使用平均值方法計算，即為平均池化層，最後再將下圖大小為  $4 \times 4$  的影像壓縮為  $2 \times 2$ ，此步驟用意在於降低所需處理的數據量，且此方法不會改變影像中的物體，池化的示意圖如圖 4 所示。




圖 4 最大池化層及平均池化層說明圖

#### (4) 全連接層(Fully-connected layer)

全連接是矩陣展開的過程，也就是將上步驟輸出的矩陣(假設大小為  $p \times p$ )與一個  $p \times 1$  的矩陣做矩陣運算。

以上述步驟為基礎進行的為基礎的模型包含有 AlexNet、VGG16、ResNet、DenseNet 等等經典模型，本研究分別使用這些模型進行影像顏色特徵的萃取。詳細說明如下方敘述：

##### (1) AlexNet

首先輸入  $224 \times 224$  的彩色影像，再經過五個卷基層（大小分別為  $11 \times 11$ 、 $5 \times 5$ ，其餘皆為  $3 \times 3$  及三個全連接層，其中再第一、第二、第五的卷積層後使用池化層，池化層採用  $3 \times 3$  的平均池化層，第六層道第八層為全連接層。AlexNet 對 RGB 三個通道的處理方式為對三個通道做主成分分析(PCA)，再使用高斯擾動，將光照影響和顏色做轉換。

##### (2) VGG16

VGG16 內包含 13 層  $3 \times 3$  卷積層、3 層連接層、5 層  $2 \times 2$  最大池化層。由於其模型使用較小的過濾器，參數也較多，因此具有很高的擬合能力，但同時也存在著訓練時間長、需要很大的儲存容量等等的缺點。

表 1 AlexNet 與 VGG16 的比較

	AlexNet	VGG16
影像大小規定	$224 \times 224$	無
卷積層大小	$11 \times 11, 5 \times 5, 3 \times 3$ (大)	$3 \times 3$ (小)
RGB 空間處理	有	無
池化層	$3 \times 3$ 平均池化層	$2 \times 2$ 最大池化層
卷積層層數	5	16
使用 Dropout	是	是
全連接層數目	3 層	3 層

##### (3) ResNet

ResNet 特別的地方在於使用 Residual Block，Residual Block 有兩種，第一種為連續使用兩個  $3 \times 3$  的卷積層，再進行一次 Shortcut Connection；第二種方法的誕生是為了降低維度，因此先使用  $1 \times 1$  卷積層降低維度，再經過  $3 \times 3$  卷積層，最後通過  $1 \times 1$  的卷積層，目的為恢復原本的維度。



ResNet 架構中的第一層為  $7 \times 7$  的卷積層，接著為  $3 \times 3$  的最大池化層，並使用很多的 Residual Block，最後使用全域平均池化(Global Average Pooling)方法傳入全連接層進行分類。

#### (4) DenseNet

DenseNet 特別的地方在於使用了 Dense block，它先後採用了 Batch Normalization、ReLU、 $3 \times 3$  卷積層，Dense block 內的每層都會接受前面所有的層的輸入，此外它可以輸入任意數目的通道，當輸入通道數量越多，層數越多，輸出的通道數也會增加。

而過度層(Transition Layer)用於連接兩個 Dense block，它是由  $1 \times 1$  卷積層和  $2 \times 2$  平均池化層所組成的，用於使特徵圖的維度大小降低。

DenseNet 的架構中的第一層為  $7 \times 7$  的卷積層，接著為  $3 \times 3$  的最大池化層，並使用很多的 Dense block 和 Transition Layer 最後傳入全連接層進行分類的方法為全域平均池化，下圖 5 為 DenseNet 流程圖：




圖 5 DenseNet 流程圖

表 2 ResNet 與 DenseNet 的比較

	ResNet	DenseNet
網路連接方式	連接上一層	互相連接所有的層
第一層卷積層大小	$7 \times 7$	$7 \times 7$
第一層池化層	$3 \times 3$ 最大池化層	$3 \times 3$ 最大池化層
最終的池化層	全局均值池化層	全局均值池化層

茲將本計畫研究方法的流程圖整理如圖 6 所示：

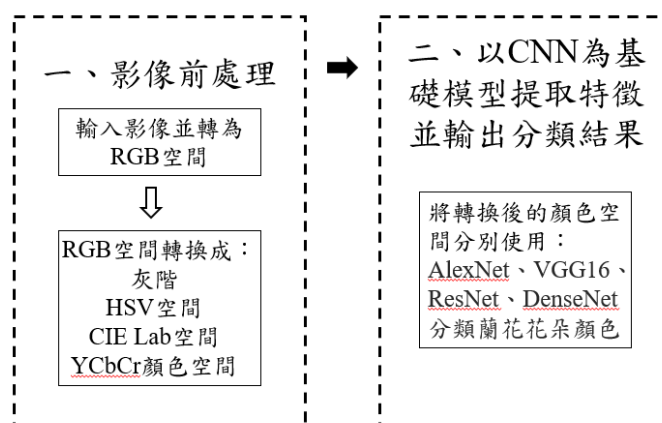


圖 6 研究方法流程圖

## (五)研究結論與比較

### 1. 評測標準

為了評測使用本計畫所提出的深度學習網路的結果，本研究使用準確率(Accuracy)、召回率(Recall)、靈敏度(Sensitivity)、F1 score 為評判準則，茲將各評測標準定義如下，其中 tp 為事實為真且預測為陽性；fp 為事實為假且預測為陽性；tn 為事實為真且預測為陰性；fn 為事實為假且預測為陰性。

#### (1) 準確率：

$$\text{準確率} = \frac{tp + tn}{tp + fp + fn + tn}$$

#### (2) 召回率：

$$\text{召回率} = \frac{tp}{tp + fn}$$

#### (3) 精確度：

$$\text{精確度} = \frac{tp}{tp + fp}$$

#### (4) F1 score：

$$\text{F1 score} = \frac{2 \times \text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

$$\text{其中，precision} = \frac{tp}{tp + fp} ; \text{recall} = \frac{tp}{tp + fn}$$

### 2. 分類結果與比較

#### (1) 花被片(tepal)顏色分類結果比較：

花被片是最能分辨花朵主要顏色的位置，本研究將花朵被片顏色分成橘黃色、粉紫色、白色三大類，花被片為橘黃色的影像共 138 張，花被片為粉紫色的影像共 138 張，花被片為白色的影像共 54 張。

表3 花被片資料筆數表格

資料筆數	原始影像	去除背景影像	旋轉75度影像	總和
橘黃色	46	46	46	138
粉紫色	46	46	46	138
白色	18	18	18	54
總和	110	110	110	330






圖7 花被片顏色樣本(a)橘色花被片蘭花(b)黃色花被片蘭花  
(c)白色花被片蘭花(d)紫色花被片蘭花(e)粉色花被片蘭花

由於本研究的蘭花花被片顏色資料分類較不平均，為使訓練模型的每組各類別資料的比例與整體資料的各類別比例盡可能相同，因此本研究使用四折分層交叉驗證(Stratified-Kfold)來切割訓練與測試資料，表 4 為 AlexNet, vgg16, ResNet50, DenseNet 模型對應不同顏色空間所得的四折交叉驗證的平均分數及標準差。

雖然 AlexNet、DenseNet 及 vgg16 配合灰階的預測蘭花花被片顏色效果都很好，但對於使用 ResNet50 的效果卻很差，F1 score 只有 0.6745，由此可知灰階值的表現較不穩定。對於 AlexNet、DenseNet、vgg16 及 ResNet50 模型，RGB 及 HSV 顏色空間的 F1 score 預測分數皆有 0.8 以上，因此對於辨識蘭花花被片顏色，使用 RGB 及 HSV 顏色空間可以得到較佳的預測效果。

由表 4 可知，使用 vgg16 預測蘭花花被片顏色可以得到較佳且較穩定的預測效果，但模型的訓練時間相對於 AlexNet 模型來說比較久，大約需 500 秒的時間，因此若比較在乎時間長短，則可使用 AlexNet 進行訓練，也可以得到不差的預測效果。

表4 分類花被片顏色的預測結果

model	color space	time(sec)	descriptive statistics	accuracy	f1 score	recall	precision
AlexNet	Gray scale	37.86	mean	0.9789	0.9812	0.98	0.98
			standard error	0.0365	0.0326	0.0347	0.03
	RGB	197.61	mean	0.8486	0.8451	0.8338	0.8572
			standard error	0.0913	0.0956	0.1	0.0919
	HSV	41.37	mean	0.9729	0.9731	0.9712	0.9751
			standard error	0.0469	0.0466	0.05	0.0431
	CIE Lab	41.3	mean	0.7982	0.8041	0.8041	0.8041
			standard error	0.2218	0.2143	0.2143	0.2143
	yCb -Cr	42.1	mean	0.7197	0.7157	0.715	0.7163
			standard error	0.2513	0.2594	0.26	0.2588

<b>vgg16</b>	<b>Gray scale</b>	574.05	mean	0.9638	0.9682	0.9695	0.967
			standard error	0.0371	0.0351	0.0354	0.035
	<b>RGB</b>	509.09	mean	0.9699	0.968	0.9701	0.966
			standard error	0.0395	0.0409	0.0373	0.0442
	<b>HSV</b>	504.57	mean	0.9668	0.9672	0.9693	0.9652
			standard error	0.0437	0.045	0.0413	0.0485
	<b>CIE Lab</b>	411.15	mean	0.9457	0.9481	0.9493	0.947
			standard error	0.0745	0.0701	0.0704	0.0699
	<b>yCb -Cr</b>	494.47	mean	1	1	1	1
			standard error	0	0	0	0
<b>ResNet 50</b>	<b>Gray scale</b>	522.99	mean	0.6707	0.6745	0.6737	0.6754
			standard error	0.1899	0.1894	0.1906	0.1883
	<b>RGB</b>	310.86	mean	0.8098	0.7949	0.7919	0.7982
			standard error	0.1303	0.1476	0.1463	0.149
	<b>HSV</b>	287.02	mean	0.8612	0.8548	0.8548	0.8548
			standard error	0.1468	0.1507	0.1507	0.1507
	<b>CIE Lab</b>	549.43	mean	0.6881	0.6803	0.6792	0.6814
			standard error	0.0656	0.0704	0.0689	0.072
	<b>yCb -Cr</b>	527.38	mean	0.6619	0.647	0.645	0.6491
			standard error	0.2235	0.2216	0.2188	0.2245
<b>Dense-Net</b>	<b>Gray scale</b>	813.08	mean	0.9247	0.9184	0.9163	0.9206
			standard error	0.0887	0.1007	0.1041	0.097
	<b>RGB</b>	750.88	mean	0.9547	0.9529	0.9476	0.9584
			standard error	0.0513	0.057	0.0634	0.0504
	<b>HSV</b>	780.08	mean	0.9276	0.9237	0.9164	0.9315
			standard error	0.0654	0.0709	0.0781	0.0636
	<b>CIE Lab</b>	749.5	mean	0.9395	0.9355	0.9257	0.9461
			standard error	0.0307	0.0277	0.0313	0.0256
	<b>yCb -Cr</b>	812.69	mean	0.8248	0.8167	0.7861	0.8532
			standard error	0.0969	0.099	0.122	0.0721

(2) 含背景的蘭花花被片斑點顏色分類結果比較：

本研究將花朵被片斑點顏色分成粉色、紫色，其中斑點形狀有漸層、斑色狀、點狀、長條狀四類，資料筆數分別為 105 張、30 張、18 張、72 張，資料筆數共 225 張。

表5 花被片斑點分類資料筆數表格

資料筆數	原始影像	去除背景影像	旋轉75度影像	總和
粉色漸層斑點	35	35	35	105
紫色斑色狀	10	10	10	30
紫色點狀斑點	6	6	6	18
粉色長條狀斑點	24	24	24	72
總和	75	75	75	225




圖8 花被片斑點顏色樣本(a)粉色漸層斑點蘭花(b)紫色斑色狀蘭花  
(c) 紫色點狀斑點狀蘭花(d)粉色長條狀斑點蘭花

由於本研究所得的蘭花花被片斑點顏色資料分類較不平均，為使訓練模型的每組各類別資料的比例與整體資料的各類別比例盡可能相同，因此本研究使用四折分層交叉驗證(Stratified-Kfold)來切割訓練與測試資料，表 6 為 AlexNet, vgg16, ResNet50, DenseNet 模型對應到不同的顏色空間所得的四折交叉驗證的平均分數及標準差。

在分類蘭花斑點顏色中，每一模型對應各顏色空間的 F1 score 都達到 0.7 以上，與分類蘭花花被片顏色的 F1 score 只有 0.6 以上相比，此分類結果較佳。

使用灰階搭配各模型訓練後的分類結果也相較於分類花被片顏色與分數穩定許多，可能是因為在分類斑點顏色中，也考慮到每種斑點的形狀不同所致。

由表 6 可知，使用 vgg16 預測蘭花花被片顏色可以得到較佳且穩定的預測效果，但模型的訓練時間相對於 AlexNet 模型來說較久，大約需要 300 秒的時間，因此若比較在乎時間長短，則可使用 AlexNet 進行訓練，也可以得到不差的預測效果。

表6 分類花被片斑點顏色的預測結果

model	color space	time(sec)	descriptive statistics	accuracy	f1 score	recall	precision
AlexNet	Gray scale	36.38	mean	0.9472	0.9426	0.9359	0.9498
			standard error	0.0723	0.067	0.0678	0.0676
	RGB	127.54	mean	0.8946	0.8859	0.8777	0.8948
			standard error	0.1626	0.1666	0.171	0.1614
	HSV	35.67	mean	0.9868	0.9861	0.9844	0.9879

			standard error	0.0228	0.0241	0.0271	0.0209
	<b>CIE Lab</b>	32.44	mean	0.824	0.8209	0.8169	0.8252
			standard error	0.2381	0.2492	0.2527	0.2454
	<b>yCb -Cr</b>	29.31	mean	1	1	1	1
			standard error	0	0	0	0
<b>vgg16</b>	<b>Gray scale</b>	574.05	mean	0.9427	0.9388	0.9443	0.9335
			standard error	0.0716	0.0789	0.0698	0.0877
	<b>RGB</b>	322.47	mean	0.9737	0.9744	0.9744	0.9744
			standard error	0.0456	0.0444	0.0444	0.0444
	<b>HSV</b>	300.04	mean	0.9825	0.9851	0.9869	0.9833
			standard error	0.0304	0.0258	0.0226	0.029
	<b>CIE Lab</b>	301.01	mean	0.9912	0.9922	0.9922	0.9922
			standard error	0.0152	0.0135	0.0135	0.0135
	<b>yCb -Cr</b>	300.19	mean	0.9781	0.9783	0.9783	0.9783
			standard error	0.038	0.038	0.038	0.038
<b>ResNet 50</b>	<b>Gray scale</b>	212.09	mean	0.8242	0.8234	0.8226	0.8242
			standard error	0.2639	0.2647	0.2661	0.2632
	<b>RGB</b>	254.64	mean	0.8768	0.8773	0.8773	0.8773
			standard error	0.1659	0.1679	0.1679	0.1679
	<b>HSV</b>	292.18	mean	0.8015	0.798	0.7959	0.8001
			standard error	0.2058	0.2056	0.2051	0.2063
	<b>CIE Lab</b>	253.89	mean	0.8724	0.8699	0.8699	0.8699
			standard error	0.1715	0.1759	0.1759	0.1759
	<b>yCb -Cr</b>	292.06	mean	0.8767	0.8769	0.8769	0.8769
			standard error	0.1578	0.1566	0.1566	0.1566
<b>Denes-Net</b>	<b>Gray scale</b>	522.76	mean	0.8541	0.8456	0.8185	0.8752
			standard error	0.1081	0.1215	0.1264	0.1156
	<b>RGB</b>	554.78	mean	0.9251	0.9239	0.922	0.9258
			standard error	0.0905	0.0973	0.1003	0.094
	<b>HSV</b>	539.65	mean	0.8232	0.8122	0.7996	0.8263
			standard error	0.1455	0.1512	0.1591	0.1415
	<b>CIE Lab</b>	538.49	mean	0.7742	0.7639	0.733	0.7984
			standard error	0.1176	0.1193	0.1162	0.1228
	<b>yCb -Cr</b>	220.95	mean	0.7295	0.7117	0.6761	0.7552
			standard error	0.1153	0.1354	0.1554	0.1098

(3) 影像去除背景後分類蘭花斑點顏色結果比較：

本研究將探討影像中的雜訊是否會影響分類的判斷，進而使預測分類結果的分數下降，因此使用將蘭花影像的背景轉為黑色，並且每一張影像只保留一朵蘭花。

為增生資料，將去除背景的影像分別旋轉 45 度和 75 度，並將花被片斑點顏色分成粉色、紫色，其中斑點形狀有漸層、斑色狀、點狀、長條狀四類，資料筆數分別為 105 張、30 張、18 張、72 張，資料筆數共 225 張。

表7 花被片斑點分類資料筆數表格

資料筆數	去除背景影像	去除背景並旋轉45度影像	去除背景並旋轉75度影像	總和
粉色漸層斑點	35	35	35	105
紫色斑色狀	10	10	10	30
紫色點狀斑點	6	6	6	18
粉色長條狀斑點	24	24	24	72
總和	75	75	75	225




圖9 去除背景後紫色長條狀斑點顏色樣本

(a)原始影像 (b)旋轉45度影像 (c) 旋轉75度影像

由表6及表8可知，在任一顏色空間下使用AlexNet和vgg16模型，去除背景影像與有背景影像預測分類結果分數差異不大，皆維持在很高的預測分數；但在任一顏色空間下使用ResNet50和DenseNet模型，使用去除背景影像的預測分類結果分數卻進步很多，F1 score都有0.8以上，由此可知將影像中的雜訊去除後，再使用模型訓練預測會得到比較好的結果。

表8 分類去除背景影像的花被片斑點顏色之預測結果

model	color space	time(sec)	descriptive statistics	accuracy	f1 score	recall	precision
Alex-Net	Gray scale	38.08	mean	0.8202	0.8061	0.773	0.845
			standard error	0.1449	0.1626	0.1573	0.1738
	RGB	84.03	mean	0.8465	0.8481	0.8352	0.862

			standard error	0.1454	0.1489	0.1567	0.1405
			mean	0.9737	0.9667	0.9548	0.9794
	<b>HSV</b>	38.29	standard error	0.0196	0.0152	0.0194	0.0139
			mean	0.8947	0.8856	0.872	0.9
	<b>CIE Lab</b>	31.65	standard error	0.1123	0.1093	0.1201	0.0973
			mean	1	1	1	1
<b>vgg16</b>	<b>Gray scale</b>	319.99	mean	0.9737	0.9722	0.9722	0.9722
			standard error	0.0291	0.03	0.03	0.03
	<b>RGB</b>	332.53	mean	0.9868	0.0961	0.9861	0.9861
			standard error	0.0228	0.0241	0.0241	0.0241
	<b>HSV</b>	312.16	mean	0.9912	0.99	0.99	0.99
			standard error	0.0152	0.0173	0.0173	0.0173
	<b>CIE Lab</b>	332.24	mean	0.9781	0.973	0.975	0.9712
			standard error	0.0288	0.0361	0.0328	0.0394
	<b>yCb -Cr</b>	292.57	mean	0.9825	0.9822	0.9822	0.9822
			standard error	0.0175	0.0181	0.0181	0.0181
<b>ResNet 50</b>	<b>Gray scale</b>	165.59	mean	0.9781	0.9805	0.9805	0.9805
			standard error	0.0288	0.0256	0.0256	0.0256
	<b>RGB</b>	209.22	mean	0.9079	0.9137	0.913	0.9145
			standard error	0.1496	0.1406	0.1419	0.1392
	<b>HSV</b>	289.44	mean	0.9781	0.9761	0.9761	0.9761
			standard error	0.038	0.0414	0.0414	0.0414
	<b>CIE Lab</b>	248.44	mean	0.9605	0.9613	0.9598	0.9627
			standard error	0.0684	0.0671	0.0696	0.0645
	<b>yCb -Cr</b>	207.85	mean	1	1	1	1
			standard error	0	0	0	0
<b>Dense-Net</b>	<b>Gray scale</b>	550.13	mean	0.8947	0.886	0.8659	0.9077
			standard error	0.1023	0.0957	0.0935	0.1001
	<b>RGB</b>	549.42	mean	0.9605	0.9529	0.9405	0.9659
			standard error	0.0259	0.0236	0.0271	0.0202
	<b>HSV</b>	570.53	mean	0.9079	0.9053	0.8966	0.9146
			standard error	0.0826	0.0913	0.0987	0.0837
	<b>CIE Lab</b>	550.22	mean	0.8071	0.7922	0.7681	0.8197
			standard error	0.0511	0.056	0.0645	0.0467
	<b>yCb -Cr</b>	549.53	mean	0.8509	0.8336	0.8148	0.8548
			standard error	0.0362	0.0482	0.0473	0.0499



## (六)參考文獻

1. 楊玉婷(2010).全球蘭花發展現況與未來展望兼論我國蝴蝶蘭與文化蘭發展策略. *台灣經濟研究月刊*, 33,(3),(37).
2. 陳偉文, 卓柏漢, & 林莉珊. (2020). 火龍果與荔枝航照影像判釋-運用卷積神經網路影像辨識技術與作物特徵萃取分類演算法. *航測及遙測學刊*, 25(1), 25-38.
3. Garcia-Lamont, F., Cervantes, J., López, A., & Rodriguez, L. (2018). Segmentation of images by color features: A survey. *Neurocomputing*, 292, 1-27.
4. Kendal, D., Hauser, C. E., Garrard, G. E., Jellinek, S., Giljohann, K. M., & Moore, J. L. (2013). Quantifying plant colour and colour difference as perceived by humans using digital images. *PLoS one*, 8(8), e72296.
5. Sağ, T. and M. Çunkaş (2015). Color image segmentation based on multiobjective artificial bee colony optimization. *Applied soft computing* 34, 389-401.
6. Toure, S., Diop, O., Kpalma, K., & Maiga, A. S. (2018). *Best-performing color space for land-sea segmentation*. Paper presented at the 2018 41st International Conference on Telecommunications and Signal Processing (TSP).
7. Kim, K., & Yu, C. (2017). Flower recognition system using openCV on android platform. *Journal of the Korea Institute of Information and Communication Engineering*, 21(1), 123-129.
8. Guru, D., Sharath, Y., & Manjunath, S. (2010). Texture features and KNN in classification of flower images. *IJCA, Special Issue on RTIPPR* (1), 21-29.
9. Toğaçar, M., Ergen, B., & Cömert, Z. (2020). Classification of flower species by using features extracted from the intersection of feature selection methods in convolutional neural network models. *Measurement*, 158, 107703.
10. Liu, Z., Wang, J., Tian, Y., & Dai, S. (2019). Deep learning for image-based large-flowered chrysanthemum cultivar recognition. *Plant methods*, 15(1), 1-11.